

Système de détection et d'alerte précoce des cybermenaces ciblant les PME

Document de cadrage • 15 juillet au 31 août 2026 (3 jalons de 15 jours)

1. Contexte et esprit du projet

Les petites et moyennes entreprises (PME) sont devenues des cibles privilégiées pour les cybercriminels, car elles manquent souvent de ressources dédiées à la cybersécurité. Ce stage vise à développer un prototype capable de détecter et de notifier en temps quasi réel les menaces émergentes ciblant les PME — en se concentrant sur le phishing (hameçonnage), une menace courante et bien documentée — en s'appuyant sur une source de Threat Intelligence publique et un modèle simple de Machine Learning.

Important : ce stage est pensé comme un parcours d'apprentissage guidé, pas comme la livraison d'un produit complet et complexe. Chaque brique est choisie pour rester accessible à un stagiaire sans expertise préalable poussée sur le sujet.

Le prototype final fera, de bout en bout :

- Récupérer des adresses web (URLs) suspectes depuis une source publique gratuite.
- Détecter automatiquement les URLs de phishing à l'aide d'un modèle simple de Machine Learning.
- Afficher les résultats dans un petit tableau de bord web.
- Envoyer une alerte par e-mail lorsqu'une menace est détectée.
- Proposer quelques fiches réflexes indiquant à une PME quoi faire face à la menace.

2. Plan de travail

Le stage se déroule du 15 juillet au 31 août 2026, en trois jalons de 15 jours. À la fin de chaque jalon, le stagiaire envoie à l'encadrant son avancement et le livrable prévu.

Jalon 1 — Découvrir et prendre en main

15 au 31 juillet 2026

Objectif : Comprendre les notions de base et préparer son environnement de travail.

- Se documenter sur le phishing et la notion d'URL malveillante (avec ses propres mots).
- Installer Python et les outils nécessaires (pandas).
- Écrire un premier petit script qui télécharge une liste d'URLs malveillantes depuis UNE source gratuite (URLhaus ou PhishTank).

Livrable : Courte note expliquant ce qu'est le phishing + le script de téléchargement des URLs.

Point de contrôle encadrant : Vérifier que les concepts de base sont compris et que l'environnement fonctionne.

Ressource pour démarrer : URLhaus (abuse.ch) : <https://urlhaus.abuse.ch> • PhishTank : <https://phishtank.org>

Jalon 2 — Construire un premier détecteur

1er au 15 août 2026

Objectif : Entraîner un modèle simple qui reconnaît une URL de phishing.

- Récupérer un jeu de données de phishing déjà étiqueté (Kaggle ou UCI).
- Entraîner UN seul modèle simple avec scikit-learn en suivant un tutoriel (régression logistique ou arbre de décision).
- Séparer les données d'entraînement et de test, puis lire les résultats (bonnes détections / erreurs).

Livable : Script qui entraîne le modèle et affiche son taux de réussite, avec quelques phrases d'explication.

Point de contrôle encadrant : Vérifier la démarche (test séparé de l'entraînement) et que le stagiaire sait expliquer son modèle.

Ressource pour démarrer : Tutoriel scikit-learn : <https://scikit-learn.org/stable/tutorial/index.html>

Jalon 3 — Assembler, afficher et alerter

16 au 31 août 2026

Objectif : Relier les morceaux en un prototype complet et le documenter.

- Créer un petit tableau de bord avec Streamlit (en Python, sans développement front-end).
- Envoyer un e-mail automatique lorsqu'une URL dangereuse est détectée (module smtplib).
- Rédiger 2 à 3 fiches réflexes simples (ex. « un employé a cliqué sur un lien de phishing : que faire ? »).
- Rédiger la documentation et préparer la présentation finale.

Livable : Prototype complet fonctionnel (démonstration), fiches réflexes et rapport de stage.

Point de contrôle encadrant : Vérifier que la chaîne fonctionne de bout en bout et que la documentation est claire.

Ressource pour démarrer : Streamlit : <https://docs.streamlit.io> · Envoi d'e-mails Python : <https://docs.python.org/3/library/smtplib.html>

3. Pile / outils (volontairement légers)

- Python avec pandas et scikit-learn pour les données et le modèle.
- Streamlit pour le tableau de bord — du Python pur, aucun front-end à apprendre.
- Un simple fichier CSV (ou SQLite) pour le stockage, au lieu d'une base complexe.
- Le module smtplib de Python pour l'envoi d'e-mails.
- Une source gratuite de Threat Intelligence (URLhaus ou PhishTank).

Écartés pour cette version : TensorFlow, Elasticsearch, Kibana, React, Node.js — trop lourds pour un premier projet.

4. Extensions possibles (si le stagiaire progresse vite)

- Ajouter un deuxième type de menace (ex. adresses IP malveillantes via AbuseIPDB).
- Brancher une source de menaces en temps réel plutôt qu'un fichier statique.
- Ajouter un canal d'alerte supplémentaire, comme Telegram.

5. Conseils pour le stagiaire

- Avancez pas à pas : mieux vaut une petite brique qui marche qu'une grande à moitié faite.
- Notez vos questions et apportez-les aux points de suivi avec l'encadrant.

- Ce projet est mené par vous-même, le stagiaire : le rôle de l'encadrant principal est de vous orienter, grâce à sa connaissance des objectifs spécifiques à EMC et au CMRPI, et de mettre à votre disposition certaines données internes accessibles utiles à votre travail.
- Regroupez vos éventuelles questions et adressez-les par e-mail à l'encadrant principal, afin d'assurer un suivi régulier de l'avancement.
- L'usage raisonné d'outils d'intelligence artificielle est recommandé pour vous aider à avancer plus efficacement.
- N'hésitez pas à solliciter la co-encadrante, Pr. Mehdi Ajana, sur les aspects Machine Learning.

L'encadrant principal

Pr. Youssef Bentaleb — bentaleb@cmrpi.ma